

基于多视角特征深度迁移的风电场内机群划分及多时间尺度等值参数辨识

摘要: 为了提高风电场多机等值的精度和多场景泛化性,提出一种基于多视角特征深度迁移的风电场内机群划分及多时间尺度等值参数辨识方法,借助风电场内各机组的多视角信息,对风电场进行多机等值。首先,设计与目标聚类层联合训练的深度时空改进自编码器(Improved Auto-Encoder, IAE),用于挖掘以机群划分目标为导向的风电机组多视角潜在特征,以提高多场景适用性;然后,基于 Kullback-Leibler(KL)散度改进高斯混合模型(Gaussian Mixture Model, GMM),实现无监督划分机群后基于迁移学习和类激活映射(Class Activation Map, CAM)生成可视化热度图表达特征重要性区间,以提高可解释性;接下来,进一步提高精度,综合考虑电压、电流、有功功率和无功功率的等值偏差,构造多目标优化模型,通过基于贝叶斯和多臂赌博机的黑盒并行优化方法,同时辨识不同时间尺度的集电线路、机械结构、控制系统的等值参数。将所提方法应用于典型双馈风电场的电网侧故障和不同扰动风况场景,根据机群划分、参数辨识两步骤设计消融实验进行分析,结果验证了该方法的准确性、鲁棒性。

关键词: 风电场多机等值;多视角特征挖掘;联合训练;深度时空自编码器;迁移学习;多目标多时间尺度参数辨识

0 引言

随着“双碳”目标的提出,风电场规模逐渐增大^[1],运行场景具有随机性、波动性且含有电力电子器件,惯性小且对过电压和过电流敏感^[2],并网后的作用规律、动态特性对电力系统稳定性的影响极大^[3],亟需构建准确描述实际运行特性的模型^[4-5]。

电力系统稳定性分为功角稳定、电压稳定和频率稳定,相关问题的时间尺度为毫秒级至秒级^[3]。以常见的双馈异步风力发电机(Doubly Fed Induction Generator, DFIG)为例,由于各组成部分的时间常数差异大,其阶跃响应在时间尺度上包括微秒级的电力电子动态、毫秒级的电气动态、秒级的机电动态、秒级以上的机械动态和分钟级的风速波动等^[4],在时间轴上具有强非线性,因此DFIG是多时间尺度动态系统^[6],且数十台甚至数百台DFIG通过集电线路以串并联方式构成风电场并连接到

外部电网,风电系统与电力系统的多时间尺度相互耦合,使风电高渗透电力系统的暂态过程包含若干时窗周期。若对风电场内每一台机组及其控制系统和集电线路都详细建模,首先,其结构复杂、维数高^[7],但容量一般远小于火电机组,不仅增大了实时仿真分析的规模和时间,其有效性和准确性也面临严峻挑战;其次,在电力市场化改革的持续推进下,由于商业保密等实际原因,整机供应商也无法提供并网换流器内部详细构造、控制回路模型以及其他部分的准确参数,使风电系统信息具有不透明性;再次,由于风电场通过边界节点影响电力系统的动态行为,因此在等值前后需关注的是边界节点各变量,即并网点的外特性。因此,如何建立兼顾计算精度和速度的风电场等值模型,对于风电高渗透新型电力系统的安全稳定分析具有重要作用^[8]。

大型风电场单机等值的精度通常难以满足要求,需要进行多机等值。由于风电场内机组的运行工况具有时变性和差异性,如何对风电机组进行合理有效的分群是必须解决的首要问题,因此将风电场多机等值问题分解成3个步骤:1)选取机群划分指标;2)划分机群;3)辨识机群等值参数。

针对步骤1),常基于机组的工作区域将风速相似性作为分群指标^[9],文献[10]在此基础上提出了实用化四机等值方法,物理意义明确,但不能适应风速扰动频繁的风电场内分群;文献[11]将固定时刻的转子速度作为分群指标,不能表征风机运行状态的变化;文献[12]以桨矩角控制器的动作情况作为分群原则,不能实时获取分群指标;文献[13]和文献[14]选用多维状态变量作为分群指标,存在冗余和强相关数据影响分群精度。因此,机群划分指标应在多视角下更加全面并有效地挖掘风电场运行特性。

针对步骤2),常用聚类算法划分风电机组,如k-means聚类^[15]、模糊C均值聚类^[13]等,其中k-means应用广泛,但对初始点敏感,且需要预设k值。文献[16]基于敏感初始中心对k-means进行了

改进,但不适合处理时序问题,因为它要选取空间上的一个固定点,虽然可以把时序当作单独维度进行处理,但这样无法捕捉时序依赖。文献[17]基于迁移学习分群,为先进人工智能思想在风电机组划分中的应用提供了范例,理论上考虑了风电场运行特性和多工况适应性,但在算例中只给出了 16 机风电场至 16 机风电场的迁移,模糊了迁移学习中源域和目标域的分布相似原则,因此所提方法无法实现不同规模风电场的知识迁移,且源域的聚类中心和隶属度可直接计算,本就无需知识迁移,在目标域聚类时这两种参数改动较大,源域的计算结果参考价值较小。因此,需要结合实际问题的特性与先进人工智能思想,设计高效的分群算法。

针对步骤 3),现阶段效果较好的风电参数辨识框架普遍基于粒子群优化算法(particle swarm optimization, PSO)^[18-19],文献[18]以不同风速为激励,通过 PSO 识别等效风力机参数,在功率波动较大的情况下不够准确,文献[19]综合描述了风电参数辨识对于系统安全稳定的重要性,通过与递归最小二乘法的比较,说明了 PSO 的优越性,但基于 PSO 的参数辨识容易陷入局部最优。除此之外,风电参数辨识还可以采用卡尔曼滤波^[20]、参考模型自适应^[21]等,但其参数辨识准确度不高。因此,风电机组等值参数辨识需要更精确的方法。

为解决上述问题,本文提出一种基于多视角潜在特征的可解释性、无监督风电场内机群划分方法,并进行等值参数的多目标黑盒鲁棒辨识,最终实现数据驱动的风电场多机等值。与传统方法相比,创新之处概括如下:

1) 在多视角层面定义机群划分指标:逐层训练深度时空 IAE 以捕捉有功功率、无功功率、机端电压、电流和转子角速度的长时依赖、短距离波动及空间相关性,高非线性映射将时序数据自动嵌入低维空间^[22],数据降维的同时最大程度保留有效信息,具有较高的拟合精度和较强的泛化能力^[23];引入联合训练机制^[24],更有利于得到表达时序未标记数据分割成多个类别的潜在维度。

2) 在无监督条件下划分风电机组:引入 KL 散度并计算出其在 GMM^[25]中的梯度下降方向,不依赖工程先验知识,不需要离线标注数据,无需人工确定机群数量;基于 CAM 和迁移学习知识生成了

表达风电机组多视角特征重要性区间的 heatmap,消除了深度学习模型的“黑箱”性质,提高了可信度。

3) 全局搜索机群等值参数:根据物理特性计算机群等值参数初值,结合基于多臂赌博机的 Hyperband^[26]并行资源分配方式和贝叶斯优化中的核密度估计建模方法^[27],搭建 BOHB 黑盒并行优化框架,同时辨识不同时间尺度的风电机组等值参数。所提方法不仅适用于风电场多机等值中对任一风电机组的等值,同样适用于风电场单机等值。

1 双馈风电场内机群划分

一个实际风电场内的风电机组通常来自同一厂家且型号一致,若风速的空间分布差异不大,则风电机组的线性化模型也近似相同^[28]。大规模风电场和部分中小规模风电场覆盖的地理空间范围较大、尾流效应明显,可以划分为几个由型号相同且工况无显著差异的风电机组构成的风电机组群,再分别等值各风电机组群。如下图所示,本文提出用于划分风电场内机群的 IAE 结构,包括特征提取层、聚类层、可视化层。特征提取层用于提取机群划分指标,聚类层根据指标划分机群并反向调节指标,可视化层将指标的时序重要性区间表征为 heatmap。

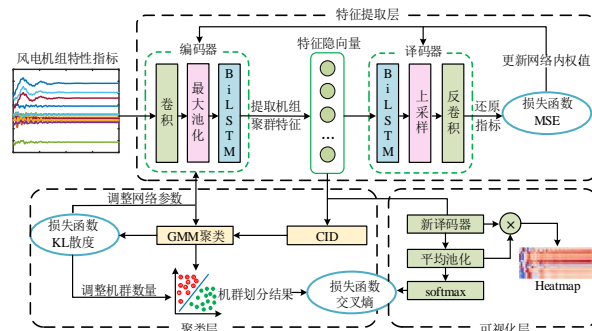


图 1 IAE 结构图

Fig. 1 Structure of IAE

2 双馈风电机组等值参数辨识

将双馈风电场内的风电机组划分为多个机群后,需要将每个机群等值为一台机组并辨识其等值参数,机群系统等值参数可以分为运行参数、结构参数、控制参数。运行参数包括风速 v 、机组视在功率 S_G 、机端变压器视在功率 S_T ;结构参数包括集电线阻抗 Z_L 、发电机阻抗 Z_G 、机端变压器阻抗 Z_T 、发电机惯性时间常数 H_g 、风力机惯性时间常数 H_w 、轴系阻尼系数 D_s 、轴系刚度系数 K_s ;控制参数包括

转子侧转速调节器增益 K_{p1} 和 K_{i1} 、转子侧变流器的电流调节器增益的 i 参数 K_{i2} 、网侧电压调节器增益的 i 参数 K_{i3} 、网侧 DC 电容电压调节器增益的 p 参数 K_{pdg} 、网侧变流器的电流调节器增益的 p 参数 K_{pg} 。

本文将双馈风电机群等值参数辨识分为两步，即机群初始等值参数计算、机群等值参数优化。

2.1 风电机群初始等值参数计算

采用容量加权法计算等值机组发电机、变压器和轴系的参数；以等值前后每一机群中风力机总输入风能相等为原则计算等值风速；根据等功率损耗法将干线式拓扑结构转换为放射式拓扑结构，再计算集电系统等值参数；控制参数取原风电机组参数。

1) 发电机及机端变压器等值参数：

$$\begin{cases} S_{Geq} = \sum_{h=1}^f S_{Gh} \\ S_{Teq} = \sum_{h=1}^f S_{Th} \\ Z_{Geq} = \frac{Z_{Gh}}{f} \\ Z_{Teq} = \frac{Z_{Th}}{f} \end{cases} \quad (13)$$

式中： S_{Geq} 、 S_{Teq} 、 Z_{Geq} 、 Z_{Teq} 是等值机的视在功率、机端变压器视在功率、发电机阻抗和机端变压器阻抗； S_{Gh} 和 Z_{Gh} 是风电机组 h 的视在功率和发电机阻抗； S_{Th} 和 Z_{Th} 是风电机组 h 的机端变压器视在功率和机端变压器阻抗； f 为等值机组包含的风电机组台数。

2) 轴系等值参数：

$$\begin{cases} H_{ieq} = \sum_{h=1}^f H_{ih} \\ H_{geq} = \sum_{h=1}^f H_{gh} \\ K_{eq} = \sum_{h=1}^f K_h \\ D_{eq} = \sum_{h=1}^f D_h \end{cases} \quad (14)$$

式中： H_{ieq} 、 H_{geq} 、 K_{eq} 、 D_{eq} 是等值机组的风力机惯性时间常数、发电机转子惯性时间常数、轴系刚度系数和轴系阻尼系数； H_{ih} 、 H_{gh} 、 K_h 、 D_h 是风电机组 h 的风力机惯性时间常数、发电机转子惯性时间常数、轴系刚度系数和轴系阻尼系数。

3) 风速等值参数：


$$\begin{cases} v_{eq} = \left(\frac{1}{Ac_{peq}} \sum_{h=1}^f A_h c_{ph} v_h^3 \right)^{\frac{1}{3}} \\ A = \sum_{h=1}^f A_h \\ c_{peq} = \frac{1}{f} \sum_{h=1}^f c_{ph} \end{cases} \quad (15)$$

式中： v_{eq} 、 A 、 c_{peq} 是等值机组的输入风速、风力机扫风面积和风能利用系数； v_h 、 A_h 、 c_{ph} 是风电机组 h 的输入风速、风力机扫风面积和风能利用系数。

4) 集电系统等值参数：

风电场内集电线路主要有两种拓扑：1) 放射式拓扑结构；2) 干线式拓扑结构。放射式拓扑结构的每台风电机组通过线路均接于 PCC 点，该拓扑结构的集电系统可直接采用等功率损耗法计算等效阻抗。干线式拓扑结构中除了首段的风电机组通过线路接于 PCC 点，其余风电机组通过线路接于其上一台风电机组线路末端，该拓扑结构的集电系统可先转换成放射式拓扑结构，再采用等功率损耗法计算等效阻抗，具体步骤如下：

1) 运用等功率损耗法分别计算干线上每台风机的等效阻抗，将其转化为放射式拓扑连接。



(a) 放射式 (b) 干线式

图3 风电场集电线路拓扑结构

如上图所示，PCC 点上有 n 台风机以干线式拓扑连接，转化成放射式拓扑连接后每台机的等效阻抗按照以下公式计算：

$$Z_{eqn} = \sum_{i=1}^n \frac{(P_1 + P_2 + \dots + P_i)^2}{P_1^2 + P_2^2 + \dots + P_i^2} Z_i \quad (16)$$

式中： n 表示任意 1 台风机； Z_i 表示第 i 台机组出口处的线路阻抗； P_i 表示流过阻抗 Z_i 的功率； Z_{eqn} 表示风机 n 支路的等效线路阻抗。




图4 干线式拓扑转换为放射式拓扑

2) 根据聚类结果, 对每一个机群中全部风机运用等功率损耗法计算总等效阻抗, 即为该等值机集电系统的等效阻抗。假设聚类结果中机群1包含 m 台风机, 将其重新由1到 m 编号, 机群1的等效阻抗为

$$Z_{eq} = \frac{\sum_{i=1}^m (P_i^2 Z_i)}{(P_1 + P_2 + \dots + P_m)^2} \quad (17)$$

式中: Z_i 表示第 i 台风机支路上的阻抗; P_i 表示流过阻抗 Z_i 的功率; Z_{eq} 表示机群1的等效阻抗。

采用等值前、后集电网络损耗相等原则计算等值阻抗的计算方法, 在风电场多机等值建模时, 一般都需要先进行复杂的网络变换将串并联混合的拓扑变为纯并联网络, 再根据等值前、后损耗相等的原则计算任意机组聚合成等值机后对应的等值阻抗, 计算较为复杂, 且在风电场内风电机组较多时, 由于计算过程中的近似, 引起的误差也会较大。

2.2 风电机组等值参数优化

风电机组参数辨识的目标是在观测量下寻找待辨识参数, 使得基于该参数的系统受扰轨线与实测轨线误差最小, 其本质是优化问题, 本文设计的风电机群等值参数优化方法步骤如下:

1) 选取风电场并网点处的有功功率、无功功率、电压和电流的等值精度构造目标函数:

$$\min F(y) = \min_y \{f_p(y), f_Q(y), f_U(y), f_I(y)\} \quad (18)$$

其中, 在工程应用中, 等值误差对电网的影响程度不仅仅由其值的大小评价, 因此采用相对偏差值来

表示等值误差, 表达式如下:

$$\begin{cases} f_p(y) = \frac{1}{M} \sqrt{\sum_{m=1}^M \left[\frac{\Delta P_{PCC}(m)}{P_b} \right]^2} \\ f_Q(y) = \frac{1}{M} \sqrt{\sum_{m=1}^M \left[\frac{\Delta Q_{PCC}(m)}{Q_b} \right]^2} \\ f_U(y) = \frac{1}{M} \sqrt{\sum_{m=1}^M \left[\frac{\Delta U_{PCC}(m)}{U_b} \right]^2} \\ f_I(y) = \frac{1}{M} \sqrt{\sum_{m=1}^M \left[\frac{\Delta I_{PCC}(m)}{I_b} \right]^2} \end{cases} \quad (19)$$

2) 确定待优化的参数 y , 包括风电机组等值控制参数、结构参数中的集电线长度和机械结构参数(发电机惯性时间常数 H_g 、风力机惯性时间常数 H_w 、轴系阻尼系数 D_s 、轴系刚度系数 K_s)。在初始参数的基础上分别增大与减小 100%, 将其作为优化区间。由于传动系统和双馈感应发电机的参数变化在影响动态响应, 目标函数和响应曲线的计算是动态的, 如果响应之间存在偏差, 说明参数发生改变, 需要动态调整参数, 最小化目标函数。

3) 针对上述参数的优化问题, 搭建 BOHB 黑盒并行优化框架。

①首先, 参考 Hyperband 的方式定义每个参数组合分配的资源(迭代次数、数据量、执行时间、缓存等)的阈值 b_{min} 、 b_{max} 和遗弃因子 η 。其中, η 大于 1, 每轮连续减半(Successive Halving, SH)策略遗弃等值误差大的参数组合的比例为 $1/\eta$ 。

定义 $s \in \{S_{max}, S_{max}-1, \dots, 0\}$, 其中, S_{max} 定义为 $\lceil \log_{\eta}(b_{max}/b_{min}) \rceil$, 大量实验表明 η 取 3 或 4 的控制效果较好, S_{max} 与 η 呈负相关, 初始总资源为:

$$B = \eta^{-s} \cdot b_{max} \quad (20)$$

②然后, 对于每一个 s , 划分为一个子集, 不同的 s 对应的子集利用不同的线程执行下述任务。基于贝叶斯建模方式从参数空间中采样出 n 个参数组合, 其中, $n = \lceil (S_{max} + 1)/(s + 1) * \eta^s \rceil$ 。

假设样本满足带核函数的高斯分布, 最开始随机选取 $N_{min} + 2$ 个参数组合(N_{min} 通常设置为 $d + 1$, d 为参数个数), 假设采样集合为 $D = \{(x_i, y_i)\}$, 其中 x_i 是参数组合、 y_i 是规定资源下的参数优化结果, 求采样函数期望的极值点 x_{i+1} 。

首先, 基于树形结构估计器(Tree-structured Parzen Estimator, TPE)分别拟合等值误差较小和等值误差较大的两个密度分布, 即 $N_{b,l}=\max(N_{min}, qN_b)$ 和 $N_{b,g}=\max(N_{min}, N_b-N_{b,l})$ 。 $N_b=|D_b|$, D_b 是预算 b 对应的观测点集合。参数组合样本点的估计概率密度为:

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K \frac{x - x_i}{h} \quad (21)$$

其中, $K_h(x)=h^{-1}K(x/h)$ 是缩放核函数; K 是核函数(非负, 实数域上积分为 1, 均值为 0); 通过最小化平均积分误差确定的带宽 h 是非负平滑参数。

当 $b=\arg\max\{D_b: |D_b| \geq N_{min}+2\}$ 时, 返回随机生成的参数组合; 否则进入开采(exploitation): 定义一个可以在大规模问题中加速收敛的概率密度 $l_{(x)}$ (使等值误差小于阈值的参数组合形成的密度的带宽乘以一个因子以鼓励围绕已知点的更多探索), 从中采样 N_s 个参数样本组合, 更新样本 x 返回使 $l_{(x)}/g_{(x)}$ 最大的参数组合($g_{(x)}$ 是使等值误差不小于阈值的参数组合形成的密度), 更新带核函数的高斯分布均值和方差, 直至在 x_{i+1} 附近采集到 n 个参数组合。

③最后, 根据线程数量将 n 个参数集合划分为含有相同数量参数组合的子集合进行并行计算, 在给定资源下每次淘汰 $1/\eta$ 比例的参数组合, 剩下的参数组合因此可以获得更多资源, 直到每个参数组合可以获得 b_{max} 资源, 比较每个子集的最优参数组合, 从而得到参数组合全局最优解。

4) 将辨识响应与实际响应进行比较, 得到有功功率响应的预测曲线, 并根据两条有功功率响应曲线的拟合度确定辨识的结构参数是否可以代替实际参数。




图5 参数辨识框架

3 双馈风电场多机等值

将本文的双馈风电场多机等值方法分为五步:

1) 输入每台双馈风电机组的有功功率、无功功率、机端电压、电流和转子角速度, 通过本文设计

的时空自编码器挖掘其数据特征, 并计算每台机组时序特征的 CID。

2) 将每台机组的 CID 输入基于 KL 散度进行梯度下降更新均值的 GMM, 通过联合训练机制反向调节步骤 1) 的参数, 使步骤 1) 倾向于挖掘能够表征时序未标记数据分割成多个机群的潜在维度, 基于迁移学习和 CAM 实现特征时序区间重要性的可视化解释。GMM 最终输出机群划分结果, 并与风电机组功率控制分区结果对比。

3) 根据步骤 2) 划分的机群, 基于容量加权法、等输入风能法、等功率损耗法计算风电场多机等值的结构参数、运行参数和集电网络参数, 控制参数保持不变, 作为步骤 4) 的初值。

4) 搭建 BOHB 黑盒并行优化框架, 在优化区间内搜索风电机组等值集电网络参数、机械结构参数和控制参数的最优解。

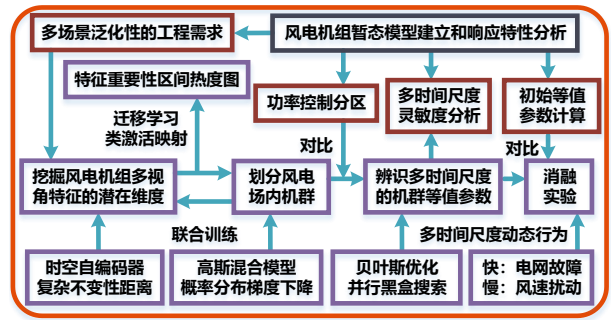


图6 风电场多机等值框架

4 算例分析

4.1 软硬件平台配置

通过编写 python 代码实现本文算法, 在软件配置方面, 本算例使用 Tensorflow 框架、Visual Studio 开发环境(包括代码编辑器、编译器、调试器等)。模型训练使用的 Linux 服务器硬件配置为 2.3GHz 八核 Intel Core i9 处理器、32GB 2667MHz DDR4 内存、ubuntu18.04 操作系统。

4.2 参数的轨迹灵敏度分析

在相同的量测条件下, 高灵敏度意味着参数变化会对系统的动态行为造成更大的影响。轨迹灵敏度的相对值定义如下:

$$S_{\theta_i} = \frac{\partial y(t) / y(t)}{\partial \theta_i / \theta_i} = \lim_{\Delta \theta_i \rightarrow 0} \frac{y(t, \theta_1, \dots, \theta_i + \Delta \theta_i, \dots, \theta_m) - y(t, \theta_1, \dots, \theta_i, \dots, \theta_m)}{y(t, \theta_1, \dots, \theta_i, \dots, \theta_m) \Delta \theta_i / \theta_{i0}} \quad (22)$$

其中, θ_i 是需要获得的灵敏度参数; θ_{i0} 表示参数的值; y 表示轨迹测量值; $\Delta \theta_i$ 表示参数的增量。

下述实验中的控制参数、结构参数中的集电线长度和机械结构参数变化 10%, 其轨迹灵敏度曲线和算术平均值见附录 B。

4.3 算例 1: 某 16 机风电场

4.3.1 风电场接线图与实验设计说明

本文利用 matlab/simulink 仿真平台, 搭建由 16 台额定功率为 1.5MW 的 DFIG 构成的风电场。DFIG 机端额定电压 575V, 由一机一变的单元接线方式就地升压至 25kV, 经过架空线路输送至 25kV/220kV 变电站并输送到外部电网, 每台 DFIG 的海拔、集电线长度及拓扑结构如下图所示。




图 7 16 机风电场接线图

每台 DFIG 原始参数如下表所示。

表 1 单台双馈风电机组原始参数

机械	大小	电气	大小	控制	大小
H_g	0.685s	S_G	1.5MVA	K_{p1}/K_{i1}	3/0.6
H_w	4.32s	Z_G	0.63Ω	K_{i2}/K_{i3}	8/20
D_s	1.5p.u.	S_r	1.75MVA	K_{pdg}	8
K_s	1.11p.u.	Z_r	0.55Ω	K_{pg}	0.83

集电线参数如下表所示。

表 2 集电线参数

电阻	Ω/km	电感	H/km	电容	F/km
正序	0.01273	正序	$0.9337e^{-3}$	正序	$12.74e^{-9}$
零序	0.3864	零序	$4.1264e^{-3}$	零序	$7.751e^{-9}$

设风向为 0°, 到此风场前的风速为 13m/s, 根据风速尾流效应, 由本算例的风电场接线图计算每台 DFIG 的初始风速如下表所示:

表 3 每台双馈风电机组的初始风速

风机编号	风速(m/s)	风机编号	风速(m/s)
1	13.0000	9	13.0000
2	12.3149	10	12.2824
3	11.8144	11	11.9069
4	10.7757	12	11.1397
5	13.0000	13	13.0000
6	12.2889	14	12.3851
7	12.0159	15	11.7793
8	11.4231	16	11.7355

不同扰动激发出的系统动态可能不同。分别设置电网侧故障和输入侧风速变化激励, 进行以下实验, 获取机组的有功功率、无功功率、电压、电流和转子角速度受扰曲线。

实验一: 在 12s 发生风电场出口三相短路故障, 故障持续 100ms, 电压跌落至 0.0 p.u.附近, 取 11s 至 17s 的数据, 步长 50us。

实验二:

1) 阵风扰动。在实验一的基础上, 通过对 simulink 中的 s_function 模块进行函数的编写, 使其在每个基础风速上加入正弦半波的扰动风速分量, 以此模拟阵风的扰动, 通过改变阵风的发生时刻, 设置仿真时长 40s, 阵风扰动时长 π s, 先后测量了三组数据进行数据分析。如下表所示。

表 4 阵风扰动实验扰动分量参数

Tab.1 Gust disturbance experiment disturbance component

parameter		
实验组号	幅值(m/s)	发生时刻(s)
1	1	3π
2	1	2π
3	1	π

2) 渐进风扰动。将基础恒定风速进行截断, 也就是设定渐进风的发生时间, 渐进的过程用正比例函数去模拟, 然后使其通过一定时间后增长至另一个恒定风速, 完成渐进风模拟。随后通过设置渐进风的发生时刻, 设置仿真时长 40s, 渐进风扰动时长 5s, 先后测出了两组数据进行分析。如下表所示。

表 5 渐进风扰动实验扰动分量参数

Tab.4 Disturbance component parameter of progressive wind

disturbance experiment		
实验组号	幅值(m/s)	发生时刻(s)
1	1	6
2	1	12

3) 综合风扰动。设置阵风发生在 2 秒, 维持 π

s, 幅值为 1m/s; 渐进风发生在 8s, 时长 5s。

4.3.2 实验一：恒风速且并网点处短路

作为对照组，基于功率控制分区特性将 16 台 DFIG 划分为最大功率跟踪区(7~12m/s)、恒转速恒功率区(12~25m/s)，即下述的 2 个双馈机群： $\{3,4,8,11,12,15,16\}$ ， $\{1,2,5,6,7,9,10,13,14\}$ 。

输入 16 台 DFIG 在 11s 至 17s 的有功功率、无功功率、电压、电流和转子角速度受扰曲线，其中功率受扰曲线如下图所示，可以看出受扰轨线的振荡频率较高，故障后约 2s 系统趋于稳态，说明电网侧故障激发了系统电气部分的快动态模式，此时电气参数的灵敏度普遍较大。且机组 4 具有明显的离群特性，符合后续分群结果。




图 8 各机组有功功率曲线




图 9 各机组无功功率曲线

联合训练本文设计的时空自编码器和概率性高斯混合模型，将双馈风电场划分为 4 个机群： $\{1,2,5,6,9,10,13,14\}$ ； $\{3,7,11,15,16\}$ ； $\{4\}$ ； $\{8,12\}$ 。此时聚类损失函数 KL 散度为 3.6877×10^{-9} ，特征损失函数 MSE 为 1.81×10^{-4} ，量级极小，在数据角度表明机群划分的精度极高、特征损失极小。

基于 CAM 构建热度图，借鉴迁移学习的思想，表达实验一在机群划分中提取的特征时序重要性区间，其颜色表示模型对特征的关注度，关注度经过归一化处理，数值越大则模型对区域特征越关注，自左而右沿时序提取特征，自上而下表示风电机组 1 至 16。




图 10 特征热度图

风速为 10.7757m/s 的机组 4 在故障切除后表现出受到特征提取层重点关注的特征，与其他机组具有明显差异，说明风电机组的聚群特征不能简单地用不同转速下的功率控制方式进行划分，还受到其他物理条件的影响。机组 3,7,11,15,16 在故障刚发生时表现出受到特征提取层重点关注的特征，随后很快不再受到关注，具有明显的聚群特性，说明机组 7 的风速虽然属于恒转速恒功率区，但是其响应特性与最大功率跟踪区的机组 3,11,15,16 相似。机组 1,2,5,6,9,10,13,14 受到模型重点关注的时间相同，与机组 8,12 只有故障刚切除的瞬间出现差异，仍然被敏锐地分为两个机群，再次说明风电机组的聚群特性不仅仅由基于风速(转速)的功率控制方式决定。

将上述两种机群划分结果分别进行多机等值参数的初始计算，即采用容量加权法计算等值机组发电机、变压器和轴系的参数；以等值前后每一机群中风力机总输入风能相等为原则计算等值风速；根据等功率损耗法将干线式拓扑结构转换为放射式拓扑结构，再计算集电系统等值参数；采用原机组控制参数作为等值控制参数。从上述初始参数的位置开始搜索，将参数辨识问题转化为非线性多目标超参数优化问题，基于 BOHB 黑盒并行优化框架，引入 early stop 机制，连续 5 次两次迭代之间损失值减小量小于阈值($1e-10$)后停止迭代，求解出最优等值参数。

为了验证本文所述风电场内机群划分、机群等值参数辨识两方面对于风电场等值精度的因果关系，设置模型 A、B、C、D 构成消融实验。将基于功率控制分区、稳态参数初始计算的多机等值模型

简称为模型 A，最大功率跟踪区、恒转速恒功率区的等值机组的等值风速分别为 11.52m/s，12.6m/s；将基于本文分群算法、稳态参数初始计算的多机等值模型简称为模型 B，机群 1 至 4 的等值风速分别为 12.668m/s、11.85m/s、10.7757m/s、11.2831m/s；将基于功率控制分区，风电机群等值控制参数、结构参数中的集电线长度和机械结构参数(发电机惯性时间常数 H_g 、风力机惯性时间常数 H_w 、轴系阻尼系数 D_s 、轴系刚度系数 K_s)综合辨识的多机等值模型简称为模型 C；将基于本文分群算法，控制参数、结构参数中的集电线长度和机械结构参数综合辨识的多机等值模型简称为模型 D。

表 6 模型 A、C 等值参数

参数	最大功率跟踪区		恒转速恒功率区	
	模型 A	模型 C	模型 A	模型 C
L	1.649km	0.037km	2.808km	0.512km
H_g	4.795s	4.315s	6.165s	7.896s
H_w	30.24s	31.72s	38.88s	66.87s
D_s	10.5p.u.	8.24p.u.	13.5p.u.	14.80p.u.
K_s	7.7p.u.	7.69p.u.	9.9p.u.	12.80p.u.
K_{p1}	3	2.2980	3	3.6568
K_{i1}	0.6	0.1962	0.6	0.1751
K_{i2}	8	5.1826	8	11.8675
K_{i3}	20	25.1496	20	16.9664
K_{pdg}	8	11.2918	8	5.0697
K_{pg}	0.83	0.5378	0.83	1.2027

表 7 模型 B、D 等值参数

参数	机群 1		机群 2		机群 3		机群 4	
	模型 B	模型 D	模型 B	模型 D	模型 B	模型 D	模型 B	模型 D
L	0.581km	0.161km	1.845km	1.010km	0.407km	0.995km	1.099km	0.587km
H_g	5.480s	6.593s	3.425s	3.546s	0.685s	0.675s	1.37s	0.872s
H_w	34.56s	63.99s	21.60s	19.35s	4.32s	7.99s	8.64s	15.96s
D_s	12p.u.	11.26p.u.	7.5p.u.	7.99p.u.	1.5p.u.	1.07p.u.	3p.u.	3.49p.u.
K_s	8.88p.u.	11.13p.u.	5.55p.u.	6.14p.u.	1.11p.u.	0.85p.u.	2.22p.u.	1.27p.u.
K_{p1}	3	3.1028	3	3.3736	3	5.0130	3	0.9074
K_{i1}	0.6	0.2585	0.6	0.4527	0.6	1.3397	0.6	0.7002
K_{i2}	8	10.4987	8	7.3191	8	12.6685	8	2.2827
K_{i3}	20	19.4199	20	18.8800	20	11.8574	20	29.6930
K_{pdg}	8	7.7930	8	5.6414	8	10.8990	8	12.3698
K_{pg}	0.83	0.9578	0.83	0.7342	0.83	0.3120	0.83	0.9441

在 simulink 搭建上述四种等值风电场模型并利用式 (19) 计算上述四种等值模型与原模型的并网节点电压、电流、有功功率和无功功率的相对等值偏差，如下表所示。

表 18 动态等值相对偏差量对比

Tab.18 Dynamic equivalent relative deviation comparison

模型	电压	电流	有功功率	无功功率
A	0.005921%	0.1216%	0.1100%	0.1600%
B	0.001491%	0.0287%	0.0299%	0.0292%
C	0.001020%	0.0007%	0.0382%	0.0830%
D	0.000356%	0.0002%	0.0039%	0.0215%

从上表可知，在本文设置的消融实验中，模型 B 相较于模型 A、模型 C 相较于模型 A 的并网节点电压、电流、有功功率和无功功率等值偏差

显著降低，分别验证本文的分群方法、参数辨识方法对于风电场动态等值精度的提升。最终，模型 D 表明本文所提模型能够更精确地模拟风电场输出的动态特性，因此完全适用于风电场与电力系统之间的交互影响分析，同时可用于含风电的电力系统稳定性分析。

为了验证本文风电场等值模型在仿真效率方面的优越性，设置固定步长 50us，即在真实风电场中 50us 迭代计算 1 次。通过 20 次实验取平均值，对比原模型与等值模型分别在 simulink、基于 gcc 编译器的 c++ 两种环境下迭代 1 次所需时间。

表 19 仿真效率对比

环境	原模型	等值模型
simulink	2102.17us	485.24us
c++	8.79us	1.39us

4.3.3 实验二：风速扰动且并网点短路

由于扰动风速的随机性，传统风电场内的机群划分表现出不确定性，采用解析方法需要不断更新机群的等值参数，而在实际工程中需要得到普遍适用于各工况的分群结果。另一方面，风速变化激发出的系统动态较慢，即与机械部分强相关的慢动态模式被激发，此时机械参数的灵敏度普遍较大。

为了得到统一性的分群结果以适用于实际工程应用中的多机等值，本文以纯数据驱动的方式将实验二设计的阵风扰动下的三组实验数据、渐进风扰动下的两组实验数据和综合风扰动下的实验数据顺次拼接输入，统一性分群结果为： $\{1,5,9,13\}\{2,6,10,14\}\{3,7,11,15,16\}\{4,8,12\}$ ，其中机群 1 至 4 的等值风速和集电线长度为 13 m/s，12.31796m/s，11.85124741m/s，11.119141m/s，1.05km，0.8081243km，3.05346177km，3.287884655km。实验一定义模型在各工况下 40s 时间窗口内的并网点等值偏差如下表所示。

表 19 模型 A 在不同场景下的等值相对偏差量

实验组号	电压	电流	有功功率	无功功率
阵风 1	0.001148%	0.0223%	0.0216%	0.2834%
阵风 2	0.001130%	0.0145%	0.0137%	0.2822%
阵风 3	0.001171%	0.0100%	0.0095%	0.2848%
渐进风 1	0.001216%	0.0145%	0.0144%	0.2902%
渐进风 2	0.001188%	0.0177%	0.0169%	0.2876%
综合风	0.001235%	0.0110%	0.0107%	0.2891%

表 20 模型 B 在不同场景下的等值相对偏差量

实验组号	电压	电流	有功功率	无功功率
阵风 1	0.000399%	0.0105%	0.0102%	0.0970%
阵风 2	0.000400%	0.0063%	0.0057%	0.0970%
阵风 3	0.000464%	0.0044%	0.0039%	0.0971%
渐进风 1	0.000458%	0.0057%	0.0060%	0.1000%
渐进风 2	0.000429%	0.0090%	0.0087%	0.0972%
综合风	0.000486%	0.0047%	0.0042%	0.0973%

表 21 模型 C 在不同场景下的等值相对偏差量

实验组号	电压	电流	有功功率	无功功率
------	----	----	------	------

阵风 1	0.000326%	0.0008%	0.0187%	0.1873%
阵风 2	0.000387%	0.0004%	0.0103%	0.1542%
阵风 3	0.000455%	0.0004%	0.0076%	0.1601%
渐进风 1	0.000479%	0.0005%	0.0088%	0.1537%
渐进风 2	0.000387%	0.0006%	0.0093%	0.1432%
综合风	0.000348%	0.0004%	0.0085%	0.1695%

表 22 模型 D 在不同场景下的等值相对偏差量

实验组号	电压	电流	有功功率	无功功率
阵风 1	0.000178%	0.0003%	0.0020%	0.0826%
阵风 2	0.000202%	0.0003%	0.0015%	0.0865%
阵风 3	0.000287%	0.0003%	0.0012%	0.0801%
渐进风 1	0.000382%	0.0004%	0.0017%	0.0792%
渐进风 2	0.000315%	0.0004%	0.0022%	0.0785%
综合风	0.000211%	0.0002%	0.0015%	0.0813%

上述实验在不同风速场景下验证了本文所提的风电场内机群划分、机群等值参数辨识方法相较于传统方法具有更高的动态等值精度，鲁棒性强，适用于实际工程中对风电场的仿真、风电与电力系统之间的交互影响与稳定性分析。

4.4 算例 2：某 32 机风电场及附近区域

4.4.1 风电场接线图与实验设计说明

某 32 机风电场及附近区域如下图所示。风电场由 32 台风电机组组成，每台风电机组通过 0.69/35kV 箱式变压器连接到集电网络，并通过 35/220kV 主变压器接入外部系统。对于外部系统，本文保留了 15kV 母线的 2 台同步机组和 500kV 母线的 1 台无限大机组；并在 15kV 及 66kV 母线处连接 5 个负荷；此外，系统包含 5 台双绕组变压器和 2 台三绕组变压器，在三绕组变压器的 66kV 侧，连接有并联电容器与电抗器。

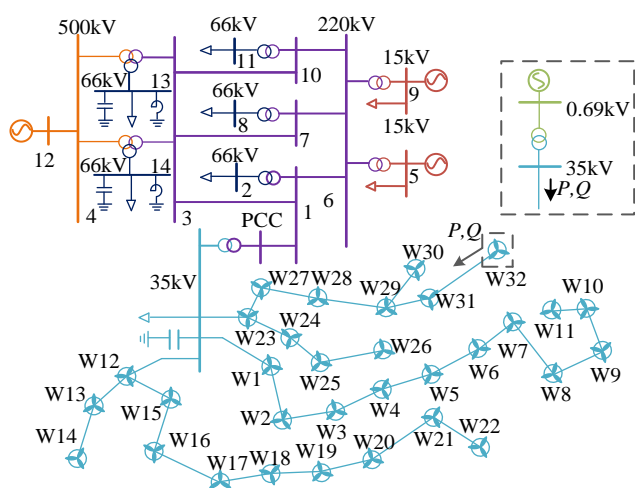


图 11 32 机风电场及其附近区域接线图




图 12 10 米高风速风向特征分布图

4.5 算例 3：风电汇集区域

4.5.1 风电汇集区域接线图与实验设计说明

对于我国常见的风电基地，整个风电汇集区域可能包含数个风电场，每个风电场中均包含若干风机，最终整个风电汇集区域的可能接入数百台风机，接入规模达到千万 kW 级。由于风电汇集区域的结构与风电场相比存在较大差异。为验证所提模型在风电汇集区域中的适用性，本文对算例 2 中包含 32 台风机的风场进行扩展，即下图所示的风电汇集区域仿真模型，该风电汇集区域共有 160 台风电机组。

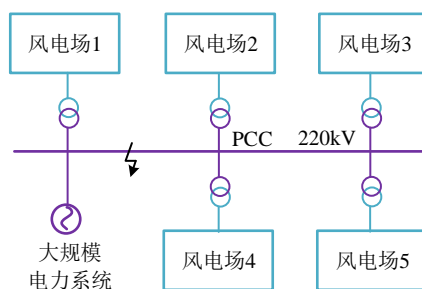


图 13 风电汇集区域图

5 结论

本文提出了一种基于多视角特征深度迁移的风电场内机群划分方法，构建了多目标非线性多时间尺度的机群等值参数辨识模型并基于 BOHB 黑盒并行优化框架进行求解。根据理论分析和消融实验，结论如下。

1) 本文搭建的深度时空自编码器与 KL-GMM 联合训练，实现多视角、无监督的风电场内机群划分，相较于传统方法，在恒风速实验条件下降低风电场并网点处电压、电流、有功功率和无功功率等值偏差约 75%、76%、73%、82%，且在变风况下可以得到统一的分群结果，满足实际工程中对于风电场等值的要求，在各类风况下的等值偏差均有 50% 至 80% 的降低，准确性、鲁棒性强，完全由数据驱动且无需离线标注数据，基于迁移学习和 CAM 实现的特征重要性区间热度图也解决了“黑箱”不可解释的问题，使其应用于实际工程中更加可靠。

2) 本文根据物理特性计算机群等值参数初值，基于 BOHB 搭建辨识机群等值参数最优值的黑盒并行优化框架，可以同时辨识风电机组中不同时间尺度的动态参数(电气、机械、控制参数)，相较于传统方法，在恒风速条件下降低风电场等值的电压、电流、有功功率和无功功率偏差约 83%、99%、65%、48%，在各类风况下也均有 40% 至 99% 的降低。

本文所提的机群划分、参数辨识方法，相较于传统方法，整体在恒风速实验条件下降低风电场等值的电压、电流、有功功率和无功功率偏差约 94%、99%、96%、86%，在各类工况下的等值偏差均有 80% 至 99% 的降低，准确性、鲁棒性强，能够更精确地模拟风电场输出的动态特性，因此完全适用于风电场与电力系统之间的交互影响分析，同时可用于含风电的电力系统稳定性分析，并且具有推广至

以永磁直驱型风电机组和光伏发电单元为代表的全功率型变换器并网机组等值的可行性。

参考文献

- [1] 徐潇源, 王晗, 严正, 鲁卓欣, 康重庆, 谢开贵. 能源转型背景下电力系统不确定性及应对方法综述[J]. 电力系统自动化, 2021, 45(16): 2-13.
- [2] 李禹鹏. 基于时频变换和辨识聚合的大规模新能源并网系统多速率仿真研究[D]. 上海交通大学, 2020.
- [3] 谢小荣, 贺静波, 毛航银, 李浩志. “双高”电力系统稳定性的新问题及分类探讨[J]. 中国电机工程学报, 2021, 41(02): 461-475.
- [4] Abad G, J López, MA Rodríguez, et al. Doubly Fed Induction Machine: Modeling and Control for Wind Energy Generation[M]. 2011.
- [5] 夏雨. 大型风电场等值建模研究[D]. 合肥工业大学, 2019.
- [6] 潘学萍, 鞠平, 吴峰, 金宇清. 双馈风电机组模型结构讨论[J]. 电力系统自动化, 2015, 39(05): 7-14.
- [7] 潘学萍, 张弛, 鞠平, 吴峰, 金宇清, 张源. 风电场同调动态等值研究[J]. 电网技术, 2015, 39(03): 621-627.
- [8] Wang Peng, Zhang Zenyuan, Huang Qi, et al. Improved wind farm aggregated modeling method for large-scale power system stability studies[J]. IEEE Transactions on Power Systems, 2018, 33(6): 6332-6342.
- [9] Meng Z J, Xue F. An Investigation of the Equivalent Wind Method for the Aggregation of DFIG Wind Turbines[C]// Power and Energy Engineering Conference (APPEEC), 2010 Asia-Pacific. 2010.
- [10] 晁璞璞, 李卫星, 金小明, 齐金玲, 常学飞. 基于有功响应的双馈型风电场实用化等值方法[J]. 中国电机工程学报, 2018, 38(06): 1639-1646+1900.
- [11] 米增强, 苏勋文, 杨奇逊, 等. 风电场动态等值模型的多机表征方法[J]. 电工技术学报, 2010, 25(5): 162-169.
- [12] 米增强, 苏勋文, 余洋, 王毅, 吴涛. 双馈机组风电场动态等效模型研究[J]. 电力系统自动化, 2010, 34(17): 72-77.
- [13] Zou J, Peng C, Xu H, et al. A Fuzzy Clustering Algorithm-Based Dynamic Equivalent Modeling Method for Wind Farm With DFIG[J]. IEEE Transactions on Energy Conversion, 2015, 30(4): 1-9.
- [14] 陈树勇, 王聪, 申洪, 高宁超, 朱琳, 兰华. 基于聚类算法的风电场动态等值[J]. 中国电机工程学报, 2012, 32(04): 11-19+24.
- [15] 杨茂, 董骏城. 基于混合分布模型的风电功率波动特性研究[J]. 中国电机工程学报, 2016, 36(S1): 69-78.
- [16] 林俐, 潘险险, 张凌云, 等. 基于免疫离群数据和敏感初始中心的 K-means 算法的风电场机群划分[J]. 中国电机工程学报, 2016, 36(20): 5461-5468.
- [17] 韩估, 苗世洪, 李力行, 杨炜晨, 李姚旺. 基于多视角迁移学习的风场内机群划分及等值风场参数综合优化[J]. 中国电机工程学报, 2020, 40(15): 4866-4881.
- [18] Zhou Y, Zhao L, Lee W J. Robustness Analysis of Dynamic Equivalent Model of DFIG Wind Farm for Stability Study[J]. IEEE Transactions on Industry Applications, 2018, 54(6):5682-5690.
- [19] Pan C, Xi Y, Hu Y. Grey-box Parameter Identification for Drive-train System of Large-scale Wind Turbine[C]// 2019 Chinese Control Conference (CCC). 2019.
- [20] Azad S P, Tate J E. Parameter estimation of doubly fed induction generator driven by wind turbine[C]// Power Systems Conference and Exposition (PSCE), 2011 IEEE/PES. IEEE, 2011.
- [21] Thomsen S, Kai R, Fuchs F W. Online Parameter Identification Methods for Doubly Fed Induction Generators[J]. IEEE Xplore, 2008.
- [22] Hinton, G.E. & Salakhutdinov, R.R. Reducing the Dimensionality of Data with Neural Networks[J]. Science, 2006, PP(313): 504-507.
- [23] LeCun, Y., Bengio, Y. & Hinton, G. Deep learning[J]. Nature, 2015, PP(521): 436-444.
- [24] Madiraju N S, Sadat S M, Fisher D, et al. Deep Temporal Clustering: Fully unsupervised learning of time-domain features[J]. arXiv: Learning, 2018.
- [25] Zhou B, Khosla A, Lapedriza A, et al. Learning Deep Features for Discriminative Localization[C]// CVPR. IEEE Computer Society, 2016.
- [26] Li L, Jamieson K, Desalvo G, et al. Hyperband: A novel bandit-based approach to hyperparameter optimization[J]. Journal of Machine Learning Research, 2016, 18:1-52.
- [27] Falkner S, Klein A, Hutter F. BOHB: Robust and Efficient Hyperparameter Optimization at Scale[J]. 2018.
- [28] 董文凯, 杜文娟, 王海风. 用于振荡稳定性分析的并网风电场动态等效模型[J]. 中国电机工程学报, 2021, 41(01): 75-87+399.

附录 A

目标分布的第一个优点是可以提升风电机组群的纯度, 纯度的定义如式(1)所示, 是一种常见的聚类效果外部评价指标, 评估了每个簇(风电机组群)中含有多少种样本(风电机组),

样本的种类由其真实的聚类标签决定。

$$\frac{1}{N} \sum_{l \in L} \max_{k \in K} |l \cap k| \quad (1)$$

其中, L 表示广域量测信息的真实标签集合, K 表示风电机组聚类的簇集合, N 表示风电机组样本个数。